

Procesamiento de Imágenes

UNIDAD 4 - Restauración de Imágenes

Restauración de Imágenes

El objetivo de la restauración de imágenes es **mejorar** la imagen en algún **sentido específico**.

Se puede considerar a la restauración como un proceso que trata de reconstruir o de recuperar una imagen degradada basándose en algún tipo de **conocimiento a priori** sobre el proceso de degradación.

Por lo tanto, las técnicas de restauración de imágenes se orientan al **modelado** de la degradación, es decir, a la obtención de un modelo de degradación, para luego aplicar el proceso inverso con el fin de recuperar la imagen original.

Restauración de Imágenes

Aunque podría parecer que el área de restauración de imágenes es similar al área de mejoramiento de imágenes, no son lo mismo: el mejoramiento de imágenes es mayormente un área subjetiva mientras que la restauración de imágenes es mayormente un proceso objetivo.

Las técnicas de mejoramiento de imágenes son, generalmente, procedimientos heurísticos diseñados para manipular una imagen aprovechando los aspectos psicofísicos del sistema visual humano.

En la restauración de imágenes, generalmente se debe definir algún criterio de bondad o función de costo, cuya optimización dará una estimación óptima del resultado deseado.

Restauración de Imágenes

Ejemplos

MEJORAMIENTO

El aumento del contraste se considera como una técnica de mejoramiento, puesto que se basa principalmente en que el aspecto debe ser agradable al observador (**subjetivo**).

RESTAURACIÓN

El aumento de nitidez de una imagen mediante la aplicación de una función que elimine el difuminado se considera una técnica de restauración (**objetivo**).

Restauración de Imágenes

Restauración

Proceso por el cual se intenta reconstruir o recuperar una imagen que ha sido degradada, usando conocimiento a **priori** del proceso de degradación. Las técnicas de restauración se basan en modelos del proceso de degradación y en la aplicación del proceso inverso para recuperar la imagen original.

Modelo del Proceso de Degradación/Restauración

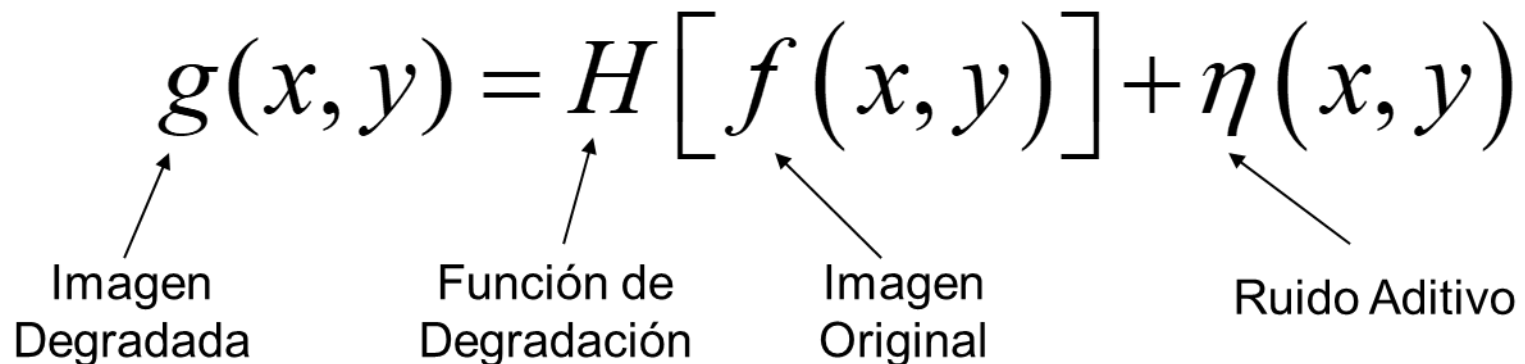

$$g(x, y) = H[f(x, y)] + \eta(x, y)$$


Diagram illustrating the degradation model equation:

- $g(x, y)$: Imagen Degradada
- H : Función de Degradación
- $f(x, y)$: Imagen Original
- $\eta(x, y)$: Ruido Aditivo

Restauración de Imágenes



Objetivo

Dada la imagen degradada $\mathbf{g(x,y)}$, algún conocimiento de la función de degradación \mathbf{H} , y algún conocimiento del ruido aditivo $\mathbf{\eta}$, el objetivo de la restauración es **obtener una estima** de la imagen original, que sea lo más **parecida** posible a la misma.

Restauración de Imágenes

Si H es un proceso lineal y espacialmente invariante, entonces:

$$g(x, y) = h(x, y) * f(x, y) + \eta(x, y)$$

donde $h(x, y)$ es la representación espacial de la función de degradación H . La representación equivalente en el dominio frecuencial resulta entonces:

$$G(u, v) = H(u, v)F(u, v) + N(u, v)$$

$H(u, v)$ \Rightarrow Optical Transfer Function (OTF)

$h(x, y)$ \Rightarrow Point Spread Function (PSF)

Modelos de ruidos

Consideraremos principalmente modelos de ruido en el dominio espacial y modelos de ruido en el dominio frecuencial.

En general, consideraremos que el ruido es independiente de las coordenadas espaciales de la imagen.

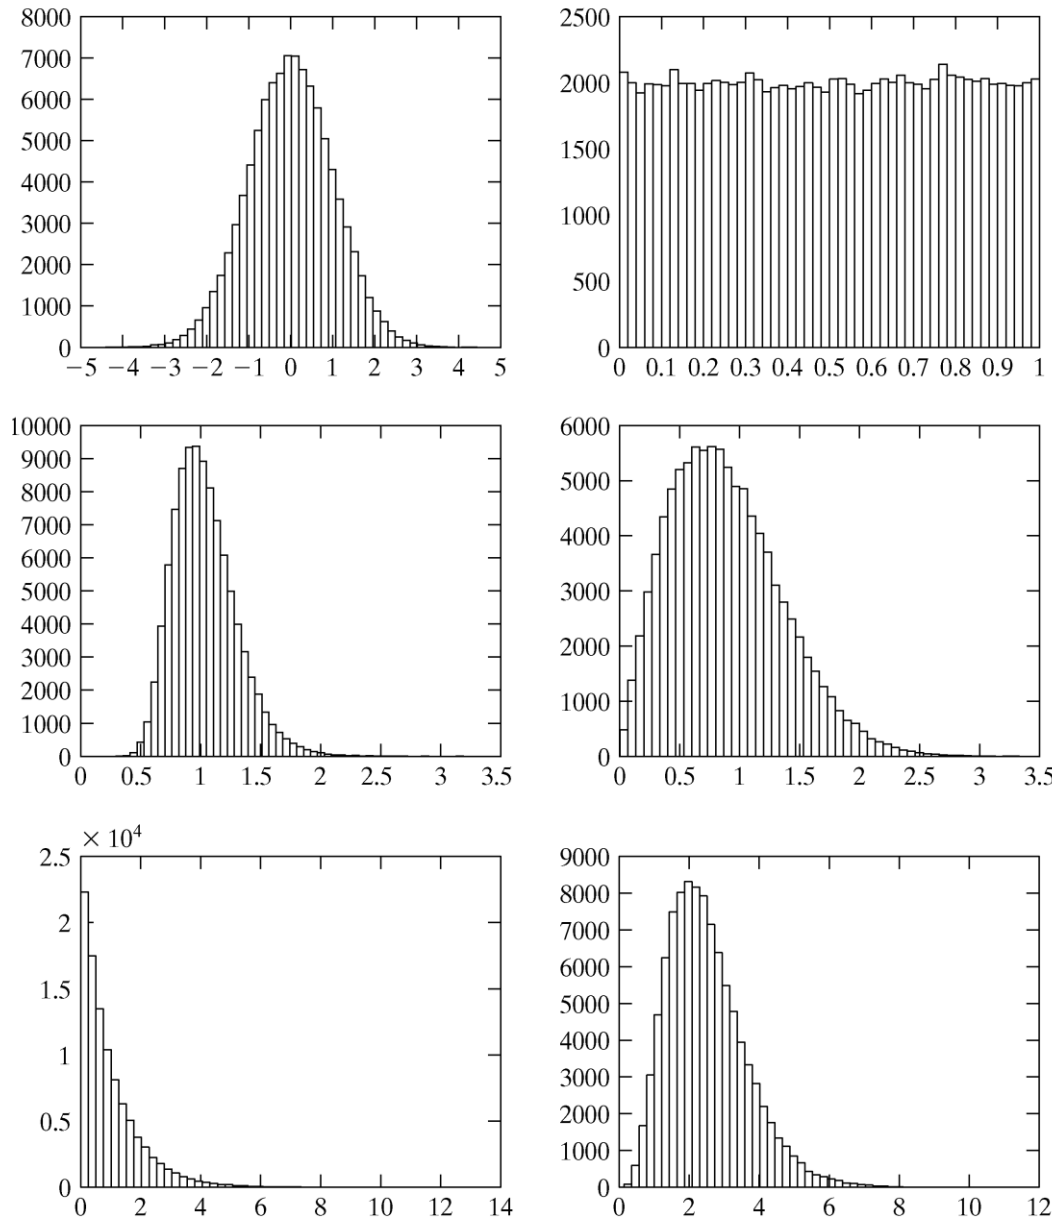
Modelos de ruidos

- **Ruido Periódico:** Aparece en imágenes debido a interferencia eléctrica o electromecánica durante la adquisición.
- **Ruido Gaussiano:** Sensores de imagen actuando con bajos niveles de iluminación.
- **Ruido Salt & Pepper:** Fallas en dispositivos de conmutación.
- **Ruido Lognormal:** El tamaño de partículas de plata en emulsiones fotográficas tiene una distribución lognormal.
- **Ruido Rayleigh:** aparece en *range imaging*.
- **Ruido Exponencial y Erlang:** es de utilidad para describir el ruido en imágenes laser.

Modelos de ruidos

Name	PDF	Mean and Variance	CDF
Uniform	$p_z(z) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq z \leq b \\ 0 & \text{otherwise} \end{cases}$	$m = \frac{a+b}{2}, \quad \sigma^2 = \frac{(b-a)^2}{12}$	$F_z(z) = \begin{cases} 0 & z < a \\ \frac{z-a}{b-a} & a \leq z \leq b \\ 1 & z > b \end{cases}$
Gaussian	$p_z(z) = \frac{1}{\sqrt{2\pi}b} e^{-(z-a)^2/2b^2}$ $-\infty < z < \infty$	$m = a, \quad \sigma^2 = b^2$	$F_z(z) = \int_{-\infty}^z p_z(v) dv$
Salt & Pepper	$p_z(z) = \begin{cases} P_a & \text{for } z = a \\ P_b & \text{for } z = b \\ 0 & \text{otherwise} \end{cases}$ $b > a$	$m = aP_a + bP_b$ $\sigma^2 = (a-m)^2P_a + (b-m)^2P_b$	$F_z(z) = \begin{cases} 0 & \text{for } z < a \\ P_a & \text{for } a \leq z < b \\ P_a + P_b & \text{for } b \leq z \end{cases}$
Lognormal	$p_z(z) = \frac{1}{\sqrt{2\pi}bz} e^{-(\ln(z)-a)^2/2b^2}$ $z > 0$	$m = e^{a+(b^2/2)}, \quad \sigma^2 = [e^{b^2} - 1]e^{2a+b^2}$	$F_z(z) = \int_0^z p_z(v) dv$
Rayleigh	$p_z(z) = \begin{cases} \frac{2}{b}(z-a)e^{-(z-a)^2/b} & z \geq a \\ 0 & z < a \end{cases}$	$m = a + \sqrt{\pi b/4}, \quad \sigma^2 = \frac{b(4-\pi)}{4}$	$F_z(z) = \begin{cases} 1 - e^{-(z-a)^2/b} & z \geq a \\ 0 & z < a \end{cases}$
Exponential	$p_z(z) = \begin{cases} ae^{-az} & z \geq 0 \\ 0 & z < 0 \end{cases}$	$m = \frac{1}{a}, \quad \sigma^2 = \frac{1}{a^2}$	$F_z(z) = \begin{cases} 1 - e^{-az} & z \geq 0 \\ 0 & z < 0 \end{cases}$
Erlang	$p_z(z) = \frac{a^b z^{b-1}}{(b-1)!} e^{-az}$ $z \geq 0$	$m = \frac{b}{a}, \quad \sigma^2 = \frac{b}{a^2}$	$F_z(z) = \left[1 - e^{-az} \sum_{n=0}^{b-1} \frac{(az)^n}{n!} \right]$ $z \geq 0$

Modelos de ruidos



a	b
c	d
e	f

FIGURE 5.2
Histograms of random numbers:
(a) Gaussian,
(b) uniform,
(c) lognormal,
(d) Rayleigh,
(e) exponential,
and (f) Erlang. In each case the default parameters were used.

Modelos de ruidos

Ruido Periódico: Aparece en imágenes debido a interferencia eléctrica o electromecánica durante la adquisición. Es dependiente de las coordenadas en la imagen, y típicamente se recurre a filtrado en el dominio frecuencial para su atenuación.

Lo modelamos como:

$$r(x, y) = A \sin \left[2\pi u_0 (x + B_x) / M + 2\pi v_0 (y + B_y) / N \right]$$

Donde A es la amplitud, u_0 , v_0 son las frecuencias respecto a los ejes x e y , respectivamente, y B_x , B_y son desplazamientos de fase respecto al origen.

Modelos de ruidos

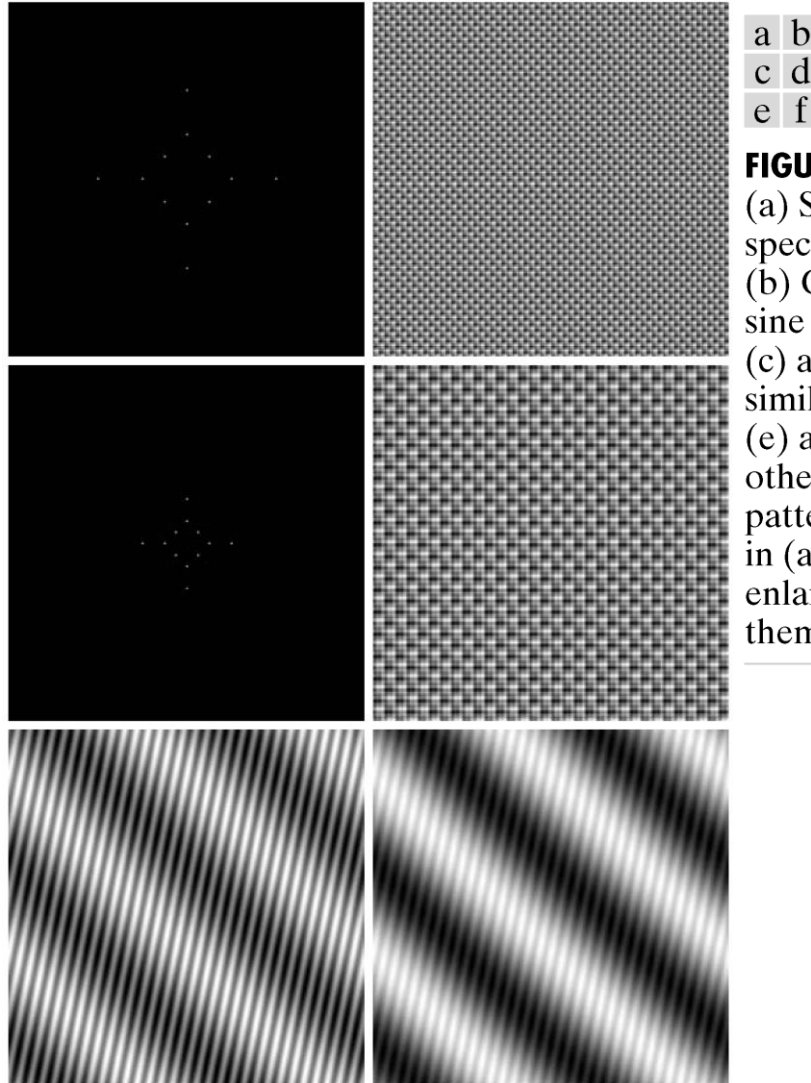


FIGURE 5.3

(a) Spectrum of specified impulses.
(b) Corresponding sine noise pattern.
(c) and (d) A similar sequence.
(e) and (f) Two other noise patterns. The dots in (a) and (c) were enlarged to make them easier to see.

Estimación de parámetros

Ruido periódico: los parámetros pueden estimarse analizando el espectro de Fourier de la imagen. Aparecen como impulsos de frecuencia que incluso pueden detectarse a simple vista.

Ruido Espacial: queda completamente caracterizado por la PDF, que puede aproximarse por el histograma de la imagen. Para describir la forma del histograma suelen usarse los **momentos centrados** (respecto a la media), definidos como:

$$\mu_n = \sum_{i=0}^{L-1} (z_i - m)^n p(z_i)$$

Estimación de parámetros

donde n es el orden del momento, L es el número de valores de intensidad posible, $p(z_i)$ es una estima de la probabilidad de ocurrencia del valor de intensidad z_i (dada por histograma normalizado) , y m es el valor medio definido como:

$$m = \sum_{i=0}^{L-1} z_i p(z_i)$$

Como el histograma está normalizado, la suma de sus componentes es 1, por lo que resulta $\mu_0=1$ y $\mu_1=0$, y el momento de segundo orden es la **varianza**:

$$\mu_2 = \sum_{i=0}^{L-1} (z_i - m)^2 p(z_i)$$

Estimación de parámetros

Frecuentemente, los parámetros del ruido deben estimarse a partir de la imagen ruidosa, o de un conjunto de imágenes.

Para ello, debe seleccionarse una región de la imagen con un fondo lo más constante en intensidad posible, de manera que la variabilidad en los valores de intensidad pueda atribuirse principalmente al ruido.

Esta región suele llamarse Región de Interés (ROI: Region of Interest).

Estimación de parámetros





FIGURE 5.4
(a) Noisy image.
(b) ROI
generated
interactively.
(c) Histogram of
ROI.
(d) Histogram of
Gaussian data.



Restauración en presencia sólo de ruido

En este caso el modelo de degradación resulta:

$$g(x, y) = f(x, y) + \eta(x, y)$$

y el método de reducción de ruido adecuado es filtrado espacial.

Filter Name	Equation
Arithmetic mean	$\hat{f}(x, y) = \frac{1}{mn} \sum_{(s,t) \in S_{xy}} g(s, t)$
Geometric mean	$\hat{f}(x, y) = \left[\prod_{(s,t) \in S_{xy}} g(s, t) \right]^{\frac{1}{mn}}$
Harmonic mean	$\hat{f}(x, y) = \frac{mn}{\sum_{(s,t) \in S_{xy}} \frac{1}{g(s, t)}}$
Contraharmonic mean	$\hat{f}(x, y) = \frac{\sum_{(s,t) \in S_{xy}} g(s, t)^{Q+1}}{\sum_{(s,t) \in S_{xy}} g(s, t)^Q}$
Median	$\hat{f}(x, y) = \text{median}_{(s,t) \in S_{xy}} \{g(s, t)\}$
Max	$\hat{f}(x, y) = \max_{(s,t) \in S_{xy}} \{g(s, t)\}$
Min	$\hat{f}(x, y) = \min_{(s,t) \in S_{xy}} \{g(s, t)\}$
Midpoint	$\hat{f}(x, y) = \frac{1}{2} \left[\max_{(s,t) \in S_{xy}} \{g(s, t)\} + \min_{(s,t) \in S_{xy}} \{g(s, t)\} \right]$
Alpha-trimmed mean	$\hat{f}(x, y) = \frac{1}{mn - d} \sum_{(s,t) \in S_{xy}} g_r(s, t)$

TABLE 5.2 Spatial filters. The variables m and n denote respectively the number of rows and columns of the filter neighborhood.

Restauración en presencia sólo de ruido

Ruido pepper:

Una buena estrategia para el filtrado del ruido pepper es el uso de un filtro contra-armónico con un valor positivo de Q . Otra alternativa es un filtro max.

Ruido salt:

Similarmente, el ruido salt puede filtrarse usando un filtro contra-armónico, con un valor negativo de Q . Otra alternativa es un filtro min.




FIGURE 5.5

(a) Image corrupted by pepper noise with probability 0.1. (b) Image corrupted by salt noise with the same probability. (c) Result of filtering (a) with a 3×3 contra-harmonic filter of order $Q = 1.5$. (d) Result of filtering (b) with $Q = -1.5$. (e) Result of filtering (a) with a 3×3 max filter. (f) Result of filtering (b) with a 3×3 min filter.

Filtrado Inverso

La manera más simple de restaurar una imagen degradada sería formar una estima de su espectro de la forma:

$$\begin{aligned}\hat{F}(u, v) &= \frac{G(u, v)}{H(u, v)} = \frac{H(u, v)F(u, v) + N(u, v)}{H(u, v)} \\ &= F(u, v) + \frac{N(u, v)}{H(u, v)}\end{aligned}$$

y luego obtener la imagen restaurada mediante la transformada inversa de Fourier. Desafortunadamente, aunque se conozca la función de degradación $H(u, v)$, el ruido es desconocido.

Filtrado Inverso

Filtro de Wiener

La idea del Filtro de Wiener es buscar una estima de la imagen original f , que minimice el error estadístico:

$$e^2 = E \left\{ \left(f - \hat{f} \right)^2 \right\}$$

La solución en el dominio frecuencial viene dada por:

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + S_\eta(u, v) / S_f(u, v)} \right] G(u, v)$$

Filtrado Inverso

$H(u, v)$ función de degradación

$S_{\eta}(u, v) = |N(u, v)|^2$ espectro de densidad de energía del ruido


$S_f(u, v) = |F(u, v)|^2$ espectro de densidad de energía de la imagen

$\frac{S_f(u, v)}{S_{\eta}(u, v)}$ relación señal-ruido (SNR)

La relación señal ruido se suele reemplazar por la relación señal ruido promedio, que es un valor escalar:

$$\frac{f_A}{\eta_A} = \frac{\frac{1}{MN} \sum_u \sum_v S_f(u, v)}{\frac{1}{MN} \sum_u \sum_v S_{\eta}(u, v)} = \frac{1}{R} \quad \longrightarrow \quad \text{Filtro de Wiener paramétrico}$$

Filtrado Inverso



a	b
c	d

FIGURE 5.8

(a) Blurred, noisy image. (b) Result of inverse filtering.

(c) Result of Wiener filtering using a constant ratio. (d) Result of Wiener filtering using autocorrelation functions.

Modelo Lineal de Borrosidad

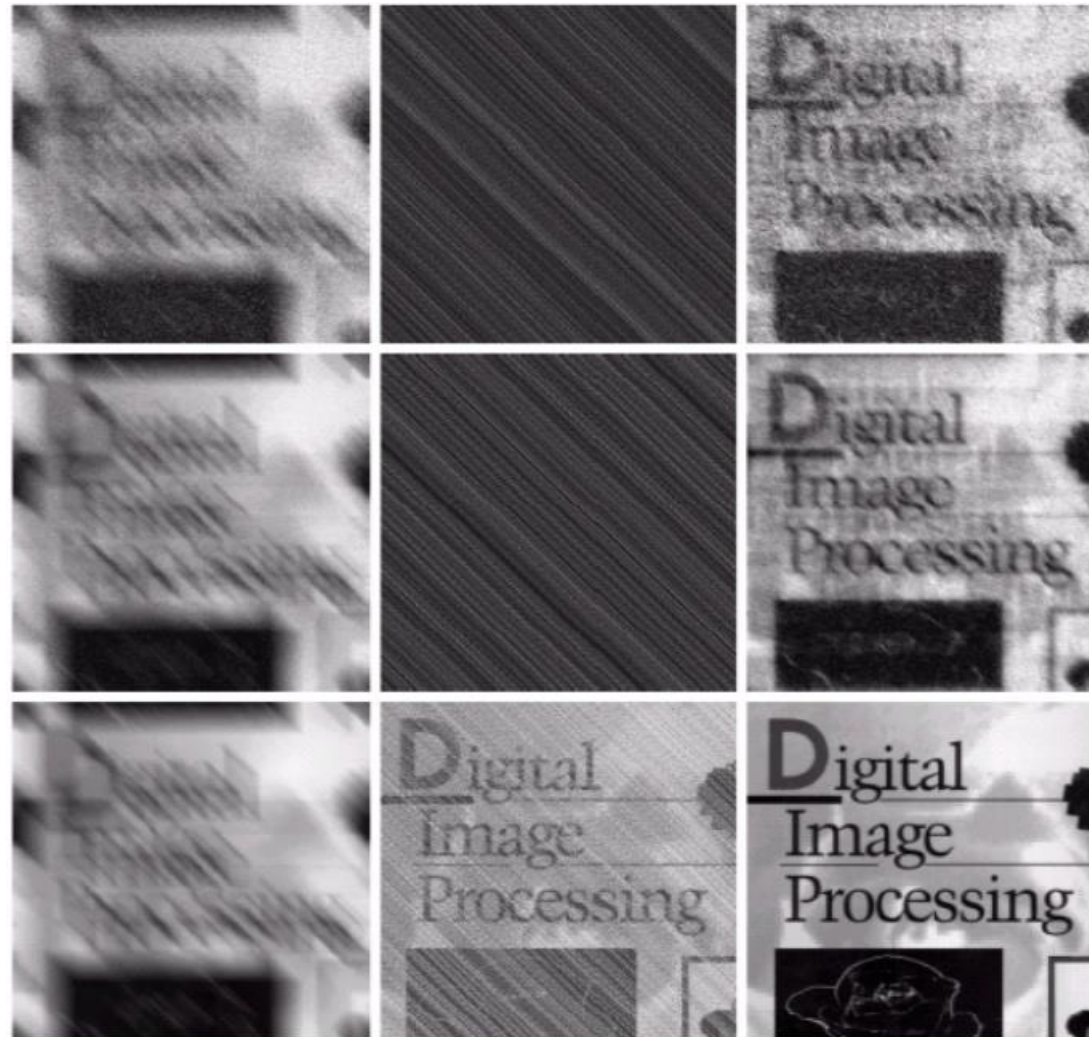
El movimiento horizontal de un objeto filmado con una video cámara puede producir una borrosidad (horizontal) en la imagen (**horizontal blurring**). Esta borrosidad se puede representar matemáticamente procesando la imagen con un filtro lineal.

La borrosidad horizontal hace que cada pixel en la imagen contenga alguna información de N pixels previos, en la misma fila. Un modelo simple de borrosidad horizontal viene dado entonces por el filtrado lineal:

$$F_b(\ell, n) = \sum_{k=\max(1, n-N)}^n F(\ell, k)h(n-k)$$



Modelo Lineal de Borrosidad



a b c
d e f
g h i

FIGURE 5.29 (a) Image corrupted by motion blur and additive noise. (b) Result of inverse filtering. (c) Result of Wiener filtering. (d)–(f) Same sequence, but with noise variance one order of magnitude less (g)–(i) Same sequence, but noise variance reduced by five orders of magnitude from (a). Note in (h) how the deblurred image is quite visible through a “curtain” of noise.

Modelo Lineal de Borrosidad

$$F_b(\ell, n) = \sum_{k=\max(1, n-N)}^n F(\ell, k)h(n-k)$$

donde $h(n)$ es la respuesta al impulso del filtro (que suponemos de longitud finita N), $F(l, k)$ denota el valor numérico de intensidad del pixel en la fila l , columna k en la imagen original, y $F_b(l, n)$ denota el valor numérico de intensidad del pixel en la fila l , columna n en la imagen con borrosidad. Notemos que si imponemos una respuesta al impulso de la forma:

$$h(n) = \frac{1}{N} \quad n = 1, \dots, N$$

entonces, la operación (**convolución discreta**) que representa la borrosidad corresponde a reemplazar el valor de intensidad de cada pixel por el promedio de los valores de intensidad de los pixeles anteriores en la misma fila.

Transformaciones Geométricas

Supongamos que la imagen f definida sobre el sistema coordenado (w,z) , sufre una distorsión geométrica dando por resultado una imagen g definida sobre un sistema coordenado (x,y) . La transformación de coordenadas se puede expresar como:

$$(x, y) = T \{ (w, z) \}$$




FIGURE 5.12 A simple spatial transformation. (Note that the xy -axes in this figure do not correspond to the image axis coordinate system defined in Section 2.1.1. As mentioned in that section, IPT on occasion uses the so-called spatial coordinate system in which y designates rows and x designates columns. This is the system used throughout this section in order to be consistent with IPT documentation on the topic of geometric transformations.)



$$(x, y) = T\{(w, z)\} = (w/2, z/2)$$

Transformaciones Geométricas

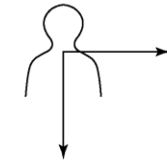
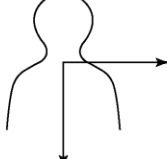
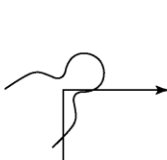
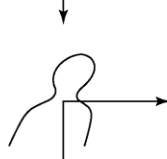
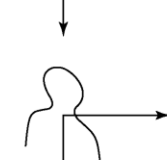
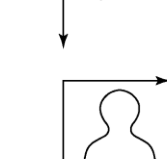
Una forma muy usada de transformación geométrica es la denominada **transformación afín**:

$$\begin{bmatrix} x & y & 1 \end{bmatrix} = \begin{bmatrix} w & z & 1 \end{bmatrix} T = \begin{bmatrix} w & z & 1 \end{bmatrix} \begin{bmatrix} t_{11} & t_{12} & 0 \\ t_{21} & t_{22} & 0 \\ t_{31} & t_{32} & 1 \end{bmatrix}$$

que permite escalar, rotar, trasladar, o deformar un conjunto de puntos, dependiendo del valor de los elementos de T.

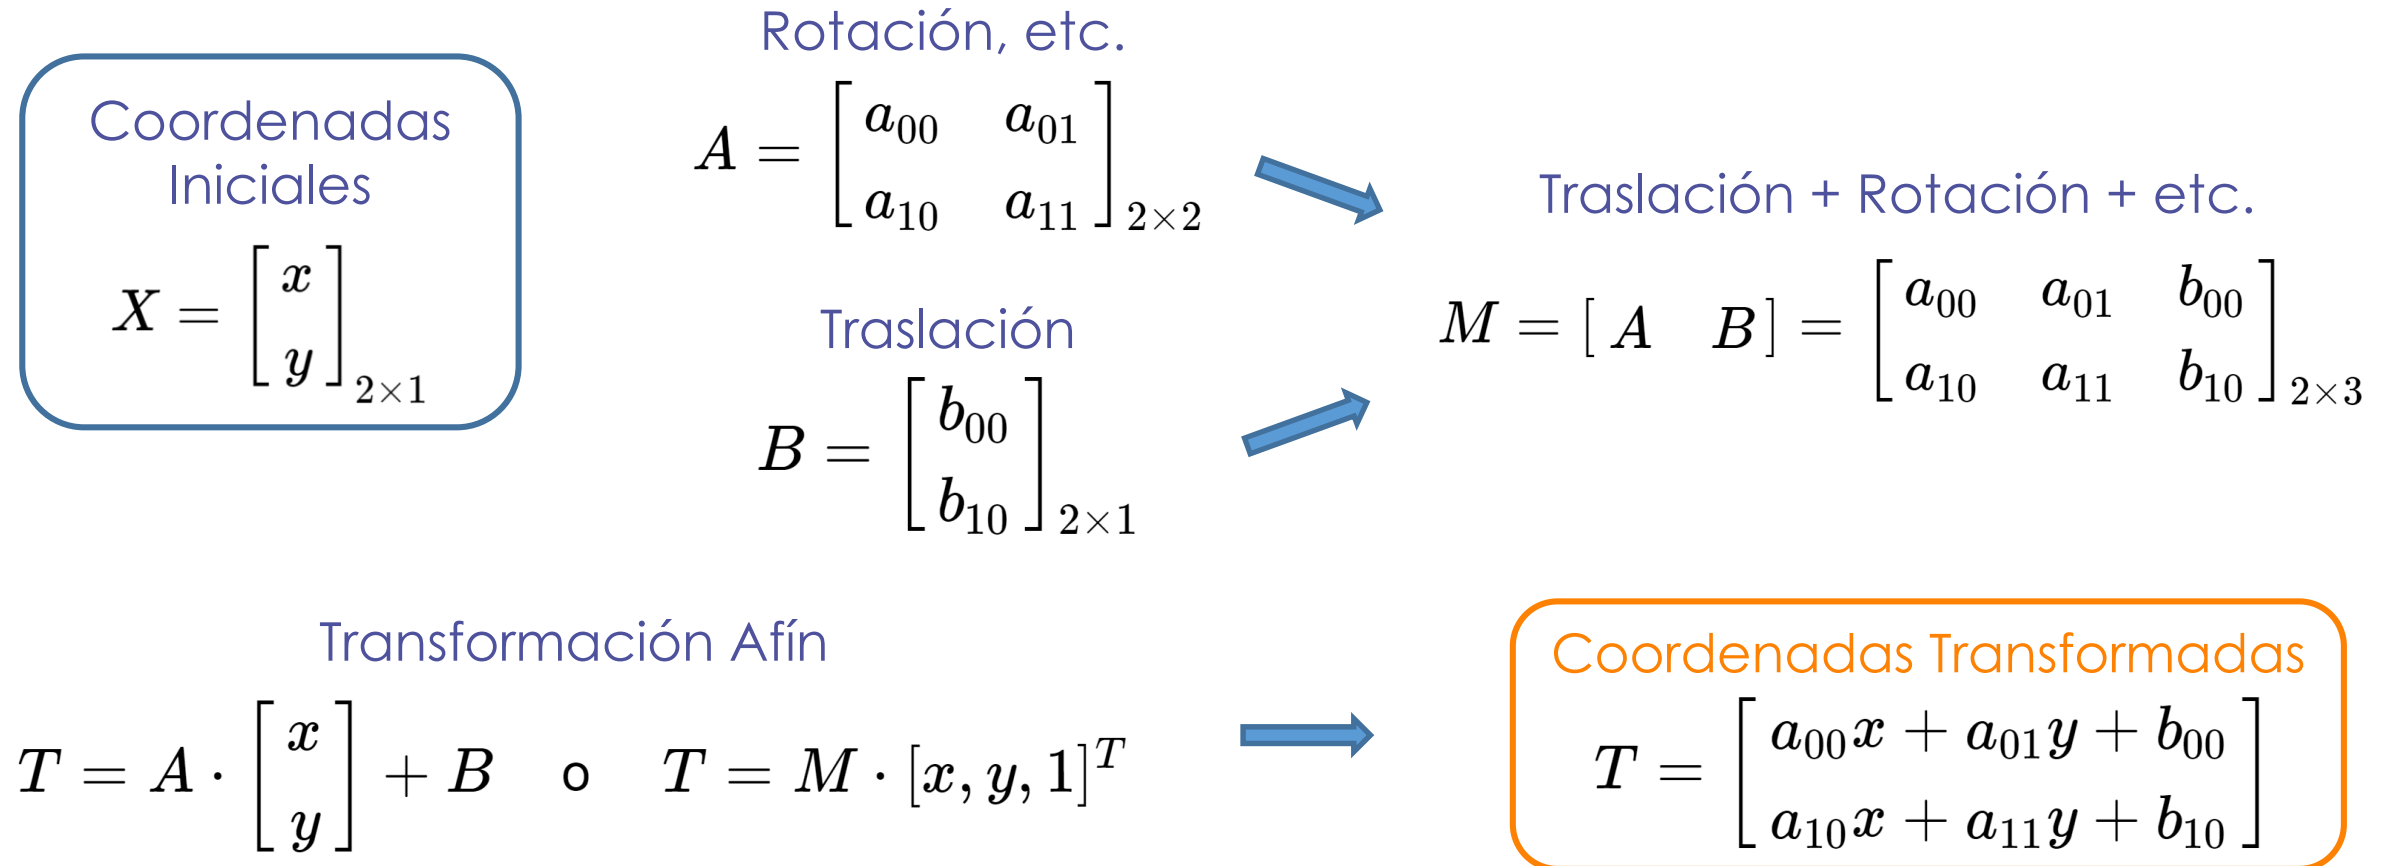
En una transformación afín, todas las líneas paralelas de la imagen original seguirán siendo paralelas en la imagen de salida.

Transformaciones Geométricas

Type	Affine Matrix, T	Coordinate Equations	Diagram
Identity	$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{aligned} x &= w \\ y &= z \end{aligned}$	
Scaling	$\begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{aligned} x &= s_x w \\ y &= s_y z \end{aligned}$	
Rotation	$\begin{bmatrix} \cos\theta & \sin\theta & 0 \\ -\sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{aligned} x &= w\cos\theta - z\sin\theta \\ y &= w\sin\theta + z\cos\theta \end{aligned}$	
Shear (horizontal)	$\begin{bmatrix} 1 & 0 & 0 \\ \alpha & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{aligned} x &= w + \alpha z \\ y &= z \end{aligned}$	
Shear (vertical)	$\begin{bmatrix} 1 & \beta & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{aligned} x &= w \\ y &= \beta w + z \end{aligned}$	
Translation	$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ \delta_x & \delta_y & 1 \end{bmatrix}$	$\begin{aligned} x &= w + \delta_x \\ y &= z + \delta_y \end{aligned}$	

Transformaciones Geométricas

OpenCV utiliza otra convención para la definición de transformaciones afines:



Transformaciones Geométricas

Una Transformación Afín es, básicamente una relación entre dos imágenes. De manera general, hay dos maneras en las cuales se utiliza una transformación afín:

1) Se conocen X y M y se desea obtener T


En este caso, solo es necesario calcular $T = M.X$. La información sobre M puede ser explícita (es decir, conocemos exactamente la matriz M) o puede provenir de la relación geométrica entre diferentes puntos (por ejemplo: puntos rotados un cierto ángulo, escalados un cierto factor, trasladados una cierta distancia, etc).

```
M = cv2.getRotationMatrix2D((cols/2,rows/2), 90, 1)
img_Tafin = cv2.warpAffine(img, M, (cols,rows))
```

Transformaciones Geométricas

2) Se conocen X y T y se desea calcular M

Dado que M relaciona las dos imágenes, podemos analizar el caso más sencillo en el que relaciona tres puntos en ambas imágenes. Observe la figura debajo: los puntos 1, 2 y 3 (que forman un triángulo en la imagen 1) son mapeados en la imagen 2, todavía formando un triángulo, pero ahora han cambiado notoriamente. Si encontramos la transformación afín con estos 3 puntos (se pueden elegirlos como sea), entonces podemos aplicar esta relación encontrada a todos los píxeles de una imagen.




```
pts1 = np.float32([[0,0],[380,0],[0,290]])
pts2 = np.float32([[0,100],[310,90],[65,200]])
M = cv2.getAffineTransform(pts1, pts2)
img_warp = cv2.warpAffine(img,M,(cols,rows))
```


Homografía

En el campo de la visión por computadora, dos imágenes cualesquiera de la misma superficie plana en el espacio se relacionan mediante una **homografía** (asumiendo un modelo de cámara *pinhole*).

“Una homografía H es una transformación proyectiva en perspectiva que determina una correspondencia biyectiva entre los puntos de dos planos.”

Esto tiene muchas aplicaciones prácticas, como la rectificación de imágenes, el registro de imágenes o el cálculo del movimiento de la cámara (rotación y traslación) entre dos imágenes.



Homografía

Una vez que la rotación y la traslación de la cámara se han extraído de una matriz de homografía estimada, esta información se puede utilizar, por ejemplo, para la navegación o para insertar modelos de objetos 3D en una imagen o video, de modo que se representen con la perspectiva correcta y parezcan haber sido parte de la escena original (*Realidad Aumentada*).

